

HR-net 对指纹特征提取

王秋恒

摘要

随着指纹采集设备的不断提升,通过高分辨率的成像技术我们可以获得含有丰富指纹特征的高精度指纹图像.由于高精度指纹图像中得汗孔可以作为活体检测的材料,并且其多级特征可以同时用于指纹识别系统,大大提高了指纹识别系统的安全性和鲁棒性.本文首次提出了一种的深度学习方法,能够在高精度指纹图像上同时提取多级特征.该方法以 HR-net 为基础网络,将指纹图像转化成关于细节点与汗孔的特征图,再通过滑动窗口进行后处理操作得到特征坐标.我们利用 HR-net 能捕捉多尺度特征的特点,在网络结构中加入中继输出使得多种特征解耦,并再网络中加入加入注意力残差结构加强网络对特征的学习.实验结果表明,该算法在汗孔的提取上,RT(准确率)达到了 0.9555,比 SOTA 提高了 2.31%,F1 score 达到了 0.9536,比 SOTA 提高了 1.01%,表明我们设计的网络能够很好地对指纹上汗孔进行提取.而且,在多级特征同时提取方面,对于汗孔的提取准确率达到 0.9681,对于细节点的提取准确率达到 0.8158.这些结果证明了本研究所提出的方法具有较高的效率和准确性。

关键词: HR-net; 指纹识别

1 引言

1.1 HR-net

随着卷积神经网络的出现,一系列复杂的视觉任务都可以通过深度学习网络来解决,帮助了人类生活的方方面面. High Resolution Net(HR-net)^[1] 是针对人体姿态估计提出的网络架构, HR-net 网络是基于热力图的,即为人体的每一个关键点都绘制一个热力图,然后网络通过热力图学习到不同关键点的特征,最终网络可以预测到不同关键点的坐标.网络架构方面, HRNet 通过并行多个分辨率的分支,加上不断进行不同分支之间的信息交互,同时达到强语义信息和精准位置信息的目的.为了保证预测的准确性, HR-net 通过全程保持高分辨率使得特征信息不会在低分辨率时丢失,这使其在位置信息敏感的任务上表现优秀;同时 HR-net 使用不断的上采样和下采样使得不同分支的信息能够交互,这使得网络能够学习到不同尺度的特征信息.



图 1: HR-net 用于姿态估计任务

1.2 高精度指纹特征

近年来,随着指纹采集设备的升级,使得高精度指纹图像应用于指纹识别系统成为了可能. 基于高精度指纹图像的 AFRS 由于可以利用三级特征,如汗孔等,相比于传统的指纹识别技术在安全性和可靠性上能有显著的提升. 而且三级特征汗孔由于其独特性,难以被伪造,是天然的活体检测材料,使得指纹系统对抗伪指纹攻击的能力大大加强. 同时,近年部分指纹识别系统在手机侧边指纹上应用广泛,使用者往往只需要手指的一部分就能完成身份认证,但是部分指纹系统所匹配的图像往往只有指纹的一小块,其一级特征和二级特征在数量和精度上都不如完整指纹图像,如果使用传统指纹系统,其安全性和鲁棒性难以得到保障. 高精度指纹图像的具有更加丰富的三级特征,即便是部分指纹图像,其特征数量也能有效帮助指纹识别系统的匹配与辨识,所以高精度指纹图像在部分指纹识别系统上有很好的应用前景.

汗孔作为指纹三级特征中最主要的特征,其数量丰富,可分辨性强,能够大大提高指纹识别系统的精确度与安全性. 同时由于汗孔在大部分指纹区域上都可见,在法医评估方面,能够对潜在的指纹图像进行判定,尤其是当指纹图像的细节点数量很有限时能发挥更大的作用^[2]. 而且指纹伪造者难以伪造指纹图像中所有的汗孔,可以利用汗孔作为活体检测材料来区分伪造指纹和真实,从而提高指纹识别系统的防伪性能.

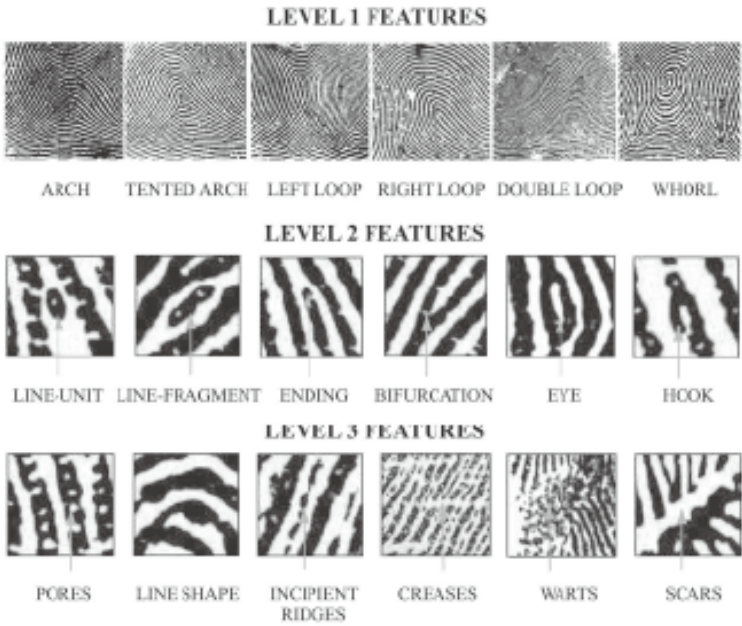


图 2: 指纹的三级特征

2 相关工作

2.1 汗孔提取方法

在自动指纹识别系统中,往往需要先对指纹图像的特征进行提取,才能进一步去做下游的匹配任务. 对于高精度指纹图像,三级特征汗孔的提取非常重要. Jonathan 等人^[3]利用汗孔在脊线上这一先验知识,先将指纹的端点进行提取,再对指纹的脊线进行跟踪搜索,进而对脊线上的汗孔进行提取. zhao 等人^[4]利用汗孔的空间分布与二维高斯分布类似这一特性,利用大小不同的两个高斯滤波器对指纹图像进行增强,相减后得到汗孔的初步图像,再经过进一步的后处理得到比较精确的汗孔分布. 随着 CNN 在图像处理领域产生的巨大影响,更多基于深度学习的汗孔提取方法被提出. jang 等人^[5]提出了

deeppore, 他们依据汗孔坐标生成热力图, 将原指纹图像输入到神经网络中, 通过连续的卷积操作后预测出汗孔的热力图, 再通过滑动窗口的搜索得到汗孔更精确的坐标. 和 deeppore 不同, labati 等人^[6]提出用两个不同的 CNN 网络完成这一任务, 第一个 CNN 通过输入的指纹图像对汗孔坐标进行初步提取, 第二个 CNN 判断提取到的坐标是否是真正的汗孔. liu 等人^[7]提出 judgeCNN, 通过将指纹图像经过二值化等预处理后, 再根据图像中心是否有汗孔将原指纹图像分成小块, 让网络学习到汗孔的特征, 进而实现汗孔坐标的精确提取.




图 3: deeppore 提取汗孔示意图

2.2 细节点提取方法

同时, 细节点作为指纹识别的重要特征, 已经有许多提取细节点的方法被提出. zhao 等人^[8]提出将指纹图像进行预处理和二值化后, 再进行骨骼化, 然后在骨骼化的脊线上进行细节点的搜索. 关于深度学习的方法, gao 等人^[9]提出利用 Gabor 相位来对指纹图像的灰度图进行细节点提取, 无需进行二值化操作, 而且可以克服图像噪声污染. Jiang 等人^[10]提出了两个 CNN 模块, 将细节点提取分成两个步骤: JudgeNet 选择出有细节点的图像块, LocateNet 预测出细节点在图像中的精确位置.

3 本文方法

3.1 基于 HR-net 的汗孔提取模型

我们用 HR-net 作为模型将汗孔的提取作为一个有监督任务. 首先, 通过汗孔坐标生成可以代表汗孔图像的热力图. 具体来说, 我们将坐标点的中心位置的热力图强度值设为 1, 远离坐标中心的强度值按照距离依次递减, 更远的点强度值设为 0. 将指纹原图和汗孔热力图作为训练样本和标签图像, 损失函数设置为均方误差损失 (mean-squared loss, MSE loss), 公式如下:

$$Loss = \frac{1}{2n} \sum_i^n (y_i - \hat{y}_i)^2 \quad (1)$$

在网络架构方面, 我们对 HR-net 网络进行了微调. HR-net 的输入是 RGB 三通道图片, 本文输入的高精度指纹图片是灰度图, 只有一个通道我们将输入通道根据实验需求进行调整. HR-net 在图片输入后会进行两次步距为 2 的下采样, 使得图片的分辨率变成原来的 1/4, 由于指纹汗孔提取是密集预测型任务, 为了保证输入输出图片大小一致, 避免精确度损失, 本文将这两层下采样层替换成了普通的卷积层. 对于网络的中间部分, 本文没有对其进行改变: HR-net 网络利用了 3 个 transition block 来进行下采样, 从而增加一个新的尺度的分支, 同时利用 3 个 stage block 对不同尺度的特征图进行上下采样, 进而可以融合不同尺度的信息. 网络中所用到的最基本的卷积结构—basic block 来自于 res-net, 利用两个卷积层和一个残差连接的结构可以使得网络向更深层次堆叠, 并解决了梯度消失和梯度爆炸的问题. 在网络的最后阶段, 我们将输出的通道数量设为 1, 保证和 ground truth 的热力图的通道数相匹配.

3.2 基于滑动窗口的指纹特征提取

得到指纹特征的热力图后, 我们最终需要得到特征的位置坐标. 本文用一个滑动窗口算法, 对热力图中的局部最大值进行搜索, 以实现特征坐标的提取 (算法 1). 具体来说, 首先我们对图像中所有像素进行遍历, 将强度值小于一个阈值的像素点的强度值设为 0, 然后我们再对其进行遍历一遍, 将每个像素点与其周围像素合成一个窗口, 遍历窗口中每一个像素, 如果该像素是窗口中强度最大的一个, 则将其标记为汗孔或者细节点.

算法 1 基于滑动窗口的坐标搜索算法

输入: 大小为 $X \times Y$ 的热力图 P

输出: 坐标点集合 U

```
1: FOR  $i = 0 ; i < x ; i ++$  DO
2:   FOR  $j = 0 ; j < y ; j ++$  DO
3:     if  $M(i,j) < P :$ 
4:        $M(i,j) = 0$ 
5:   FOR  $i = 0 ; i < x ; i ++$  DO
6:     FOR  $j = 0 ; j < y ; j ++$  DO
7:       if  $M(i,j)$  is the max of the local window:
8:         add  $(i,j)$  to  $U$ 
```

4 复现细节

4.1 与已有开源代码对比

4.1.1 加入注意力机制

注意力机制起初在自然语言处理领域被提出, 后来在计算机视觉领域也取得了很大的成效, 如 swin-transformer 模型在一系列的视觉任务上都超越了卷积神经网络. 受 a-hr-net^[11] 的启发, 本文将 hr-net 网络中的 basic block 替换成结合注意力机制的 attention block. 具体来说, 我们将一个新的注意力分支作为一个残差结构加入 basic block, 新增的分支所带来的计算量很小, 但能够大大增强网络的表征学习能力.

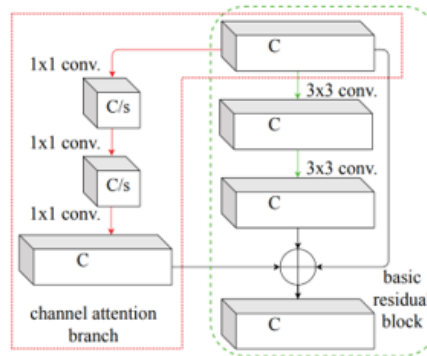


图 4: 注意力残差结构示意图

4.1.2 中继输出

由于汗孔和细节点是不同尺度的特征, 汗孔是脊线上的特征, 网络可以通过指纹脊线上的一小部分图像对汗孔进行识别. 而对于细节点, 这里主要指的是指纹脊线的端点和分叉点, 网络所需要的图像信息更广, 需要结合脊线走向等全局信息进行推理判断. 为了使网络能够适应不同尺度的特征, 我们计

算卷积神经网络的感受野. 在使用 3×3 卷积核的情况下, 对于深度为 D 的卷积神经网络, 其感受野为 $(2D + 1) \times (2D + 1)$, 在网络的中间层, 其特征图的感受野较小, 我们在这里对其进行输出通道为 1 的卷积操作, 输出的特征图即指纹汗孔的热力图. 而在网络的最终输出层, 其特征图的感受野更大, 我们同样对其进行卷积操作, 将输出图像作为细节节点的热力图.




图 5: 中继输出结构示意图

对于最终的损失计算, 我们需要一个权重超参数对两个热力图损失进行调节. 公式如下

$$Loss_{all} = \alpha Loss_{pore} + Loss_{minutiae} \quad (2)$$

4.2 实验细节

4.2.1 数据集描述

我们选择香港理工大学提供的高精度指纹图像数据集, 共有 30 张大小为 240×320 、1200DPI 的指纹图像, 包含已经被标记的 12767 个汗孔. 为了检测图像中的细节节点, 我们对指纹图像进行手工标注, 细节节点主要包括脊线的端点和分叉点, 一共有 629 个细节节点. 对于汗孔的检测, 为了保证和以前实验数据一致. 我们对指纹图像进行图像增强, 将其进行切割成 80×80 的指纹切片, 再对其进行旋转、翻转 (90° , 180° , 270°) 等操作, 一共得到 89250 张图像切片. 对于细节节点的检测, 我们考虑到细节节点需要更广尺度的信息, 将指纹图片切割成更大的 160×160 图像切片, 以保证网络可以利用到更完整的脊线信息. 同样的, 我们对其进行数据增强共得到 32130 张图像切片, 来用于细节节点的检测.

4.2.2 实验参数设置

为了减少数据集划分带来的偏差, 本文选用 5 折交叉验证法进行训练. 训练时, 本文选择 AdamW^[12] 作为网络训练的优化器, 其优势在于能够实现 L2 正则化的同时提升计算效率. 我们将优化器参数 weight decay 设置为 0.0001, 学习率设置为 0.001, 迭代次数设置为 30. 在多级特征同时提取的实验中, 由于汗孔和细节节点的数量差距较大, 我们将损失权重超参数 α 设置为 0.02, 以便细节节点有更大的损失权重. 在后处理阶段, 关于滑动窗口的大小问题会在后续的实验中讨论. 而关于算法中的阈值, 根据实验经验, 我们选取了表现最佳的阈值 0.25.

4.3 创新点

首次提出一种可以同时检测指纹上多级特征的算法, 并且能够达到较好的提取效果. 同时, 我们在网络中加入注意力机制和中继输出模块使得网络学习能力更强

5 实验结果分析

5.1 现有汗孔提取算法结果对比分析

在汗孔的提取实验中, 我们用本文所提出的模型算法进行具体实验. 将传统模型提取汗孔的效果与本文的方法进行对比, 包括了非深度学习方法与深度学习的方法. 汗孔提取对比模型包含 Jain’ s method^[13]、Adapt DoG^[4]、DAPM^[14]、CNN^[6]、DeepPore^[5]、judge CNN^[7]、Dilated U-Net^[15]我们以 RT、RF 和 F1 score 作为衡量模型检测效果的指标, 结果在表 2 中进行比较. 结果表明用我们的算法提取汗孔的 RT 达到了 0.9527, 而 F1 score 也达到了 0.9507, 优于其他网络和模型. 证明了我们选用的 HR-net 在汗孔的提取性能方面达到最佳 (表 1).

表 1 不同算法对汗孔检测的性能对比

算法	评价指标		
	RT	RF	F1 score
Jain’ s method	0.759	0.230	0.7645
Adapt DoG	0.808	0.222	0.7927
DAPM	0.848	0.176	0.8358
CNN	0.8469	0.1531	0.8469
DeepPore	0.9309	0.0864	0.9221
Judge CNN	0.9314	0.0439	0.9435
Dilated U-Net	0.9313	0.0792	0.9260
Ours	0.9527	0.0508	0.9507

5.2 多级特征提取实验

我们用 HR-net 作为网络模型, 加上注意力机制和中继输出两个新的模块, 用高精度指纹灰度图作为输入, 将汗孔的热力图作为网络的中继输出, 将细节点的热力图作为网路的最终输出. 注意力模块能够使得网络对图像的特征学习能力更加强大, 而中继输入使得两个不同级别的特征相互分别开来, 从而达到特征解耦的目的. 我们发现我们的算法在同时提取网络细节点和汗孔上能够达到较高的水平. 在同时提取的评价指标中, 汗孔和细节点是两个不同的评价样本, 分别有各自的 RT、RF 和 F1 score. 由于数据集中总汗孔的数量是 12767 个, 而总细节点的数量是 629 个, 为了更公平地衡量网络提取两种指纹特征的性能, 我们选择用 micro-F1 score 作为最终的评价指标. micro-F1 score 是汗孔的 F1 score 和细节点的 F1 score 的平均值, 可以避免汗孔和细节点数量不平衡带来的影响.

表 2 网络对多级特征同时检测结果

特征种类	评价指标			
	RT	RF	F1 score	micro-F1 score
汗孔	0.9579	0.0650	0.9456	0.8661
细节点	0.7729	0.1773	0.7866	

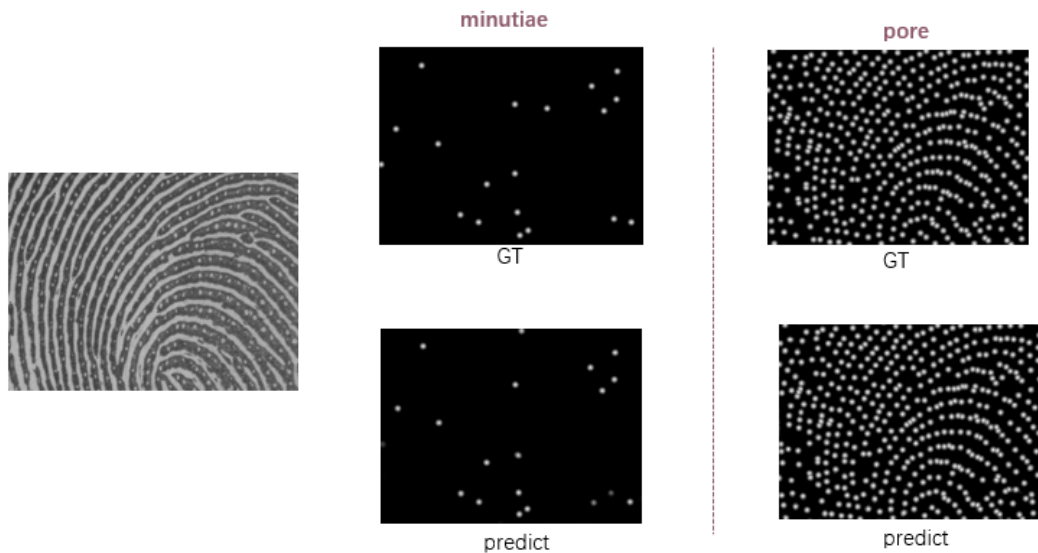


图 6: 多级特征提取实验结果示意图

5.3 验证各模块有效性的消融实验

为了验证中继输出和注意力网络这两个模块的有效性, 我们对同时提取的网络做了一些列消融实验. A 组是原有基本的 HR-net 模型, 输入指纹灰度图, 我们直接将网络的最终输出维度设置为 2, 分别对应汗孔和细节点的热力图. B 组在 A 组的基础上加入了注意力机制, 即将注意力分支作为残差结构加入网络的 basic block. C 组在 A 组的基础上使用了中继输出, 将汗孔作为中间层网络的输入, 而细节点作为最后网络层的输出. 而 D 组将两个模块都加入网络, 表现如下表所示, 可以发现同时加入两个模块的网络取得了最佳的提取效果.

表 3 消融实验验证各模块有效性

组别	特征种类	评价指标			
		RT	RF	F1 score	micro-F1 score
A	汗孔	0.9579	0.0650	0.9456	0.8661
	细节点	0.7729	0.1773	0.7866	
B	汗孔	0.9563	0.0581	0.9487	0.8694
	细节点	0.7741	0.1697	0.7901	
C	汗孔	0.9615	0.0865	0.9363	0.8693
	细节点	0.7997	0.1725	0.8024	
D	汗孔	0.9681	0.0737	0.9463	0.8878
	细节点	0.8158	0.1401	0.8293	

6 总结与展望

本文使用高精度指纹图像, 首次提出一种基于深度学习能够同时提取汗孔和细节点的算法, 利用 HR-net 作为网络结构, 并改变适合的滑动窗口的大小提高算法的准确性, 相比于传统的汗孔提取方法在精度上有很大的提高. 同时, 在网络架构中加入注意力机制和中继输出模块, 使得网络能够同时精准地提取两个不同尺度的特征. 实验表明, 本文所提出模型的性能指标目前超过了现有的最佳算法, 同时也是首个对指纹图像的汗孔和细节点进行同时提取的算法. 在之后的工作中, 我们将进一步提高网络算法的准确性和鲁棒性, 并基于提取的特征提出更好的指纹匹配算法.

参考文献

- [1] SUN K, XIAO B, LIU D, et al. Deep high-resolution representation learning for human pose estimation [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 5693-5703.
- [2] ZHAO Q, FENG J, JAIN A K. Latent fingerprint matching: Utility of level 3 features[J]. MSU Technical Report, 2010, 8: 1-30.
- [3] STOSZ J D, ALYEA L A. Automated system for fingerprint authentication using pores and ridge structure[C]//Automatic systems for the identification and inspection of humans: vol. 2277. 1994: 210-223.
- [4] ZHAO Q, ZHANG D, ZHANG L, et al. High resolution partial fingerprint alignment using pore–valley descriptors[J]. Pattern Recognition, 2010, 43(3): 1050-1061.
- [5] JANG H U, KIM D, MUN S M, et al. DeepPore: fingerprint pore extraction using deep convolutional neural networks[J]. IEEE Signal Processing Letters, 2017, 24(12): 1808-1812.
- [6] LABATI R D, GENOVESE A, MUÑOZ E, et al. A novel pore extraction method for heterogeneous fingerprint images using convolutional neural networks[J]. Pattern Recognition Letters, 2018, 113: 58-66.
- [7] LIU F, ZHAO Q, ZHANG D. Advanced Fingerprint Recognition: From 3D Shape to Ridge Detail[M]. Springer, 2020: 107-138.
- [8] FRONTHALER H, KOLLREIDER K, BIGUN J. Local feature extraction in fingerprints by complex filtering[C]//International Workshop on Biometric Person Authentication. 2005: 77-84.
- [9] GAO X, CHEN X, CAO J, et al. A novel method of fingerprint minutiae extraction based on Gabor phase[C]//2010 IEEE International Conference on Image Processing. 2010: 3077-3080.
- [10] JIANG L, ZHAO T, BAI C, et al. A direct fingerprint minutiae extraction approach based on convolutional neural networks[C]//2016 International Joint Conference on Neural Networks (IJCNN). 2016: 571-578.
- [11] LI Y, WANG C, CAO Y, et al. A-HRNet: Attention Based High Resolution Network for Human pose estimation[C]//2020 Second International Conference on Transdisciplinary AI (TransAI). 2020: 75-79.
- [12] LOSHCHILOV I, HUTTER F. Fixing weight decay regularization in adam[J]., 2018.
- [13] JAIN A K, CHEN Y, DEMIRKUS M. Pores and ridges: High-resolution fingerprint matching using level 3 features[J]. IEEE transactions on pattern analysis and machine intelligence, 2006, 29(1): 15-27.
- [14] ZHAO Q, ZHANG D, ZHANG L, et al. Adaptive fingerprint pore modeling and extraction[J]. Pattern Recognition, 2010, 43(8): 2833-2844.
- [15] DING B, WANG H, CHEN P, et al. Subcutaneous sweat pore estimation from optical coherence tomography[J]. IET Image Processing, 2021, 15(13): 3267-3280.